

最优化理论 Optimality Theory









目录(CONTENT)



- 01 课程简介(Introduction)
- 02 线性规划(Linear Programming)
- 03 非线性规划(Non-Linear Programming)
- 04 整数规划(Integer Programming)
- 05 动态规划(Dynamic Programming)





使用导数的最优化方法 Optimization Method Using Derivative

川巡守八



■主要内容

- 最速下降法
- 牛顿法
- 共轭梯度法
- 拟牛顿法
- 信赖域法

取还 门中/云



■ 概念

考虑无约束问题 $\min f(x), x \in \mathbb{R}^n$ (10.1.1) 其中 f(x)具有一阶连续偏导数。

在处理这类问题时,一般迭代策略是,希望从某一点出发,选择一个目标函数值下降最快的方向,沿此方向搜索以期尽快达到极小点,基于这一思想,Cauchy于1847年提出了**最速下降法**。这是无约束最优化中最简单的方法。

取述 []中/云



■ 概念

函数f(x)在点x处沿方向d的变化率可用方向导数表示 当函数可微时,有方向导数

$$Df(x,d) = \nabla f(x)^{T} d \quad (1.2)$$

求函数f(x)在点x处下降最快的方向,归结为求

$$\min \quad \nabla f(x)^T d$$

$$s.t \quad ||d|| \le 1 \qquad (1.3)$$

由Schwartz不等式,

$$\left|\nabla f(x)^T d\right| \le \left\|\nabla f(x)\right\| \left\|d\right\| \le \left\|\nabla f(x)\right\|$$

$$\Rightarrow \quad \nabla f(x)^T d \ge -\left\|\nabla f(x)\right\| \tag{1.4}$$

取还门冲7



■ 概念

由上式知. 当

$$d = -\frac{\nabla f(x)}{\|\nabla f(x)\|} \tag{1.5}$$

时等号成立.故在点x处沿(1.5)所定义的方向变化率最小, 即负梯度方向为**最速下降方向.**

注意:在不同的尺度下最速下降方向是不同的.

取还门中/云



■ 概念

最速下降算法的迭代公式为

$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)} \qquad (1.6)$$

其中 $d^{(k)}$ 是从 $x^{(k)}$ 出发的搜索方向, 此处取在点 $x^{(k)}$ 的最速下降方向,即 $d^{(k)} = -\nabla f(x^{(k)})$.

 λ_k 是从 $x^{(k)}$ 出发沿方向 $d^{(k)}$ 进行一维搜索的步长,即满足

$$f(x^{(k)} + \lambda_k d^{(k)}) = \min_{\lambda > 0} f(x^{(k)} + \lambda d^{(k)})$$
 (1.7)

取还门中/云



■ 算法

算法描述

Step1,给定初始点 $x^{(k)} \in E^n$,允许误差 $\varepsilon > 0$,置k = 1Step2,计算搜索方向 $d^{(k)} = -\nabla f(x^{(k)})$ Step3,若 $\|d^{(k)}\| \le \varepsilon$,停止,否则,从 $x^{(k)}$ 出发,沿 $d^{(k)}$ 进行一维搜索, 求 λ_k ,使得 $f(x^{(k)} + \lambda_k d^{(k)}) = \min_{\lambda \ge 0} f(x^{(k)} + \lambda d^{(k)})$ Step4,令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$,置k := k + 1,转Step2

取还 门中/云



■ 例子

例1.1 用最速下降法求解下列问题

min
$$f(x) = 2x_1^2 + x_2^2$$

初始点 $x^{(1)} = (1,1)^T, \varepsilon = \frac{1}{10}$

第一次迭代

目标函数f(x)在点x处的梯度

$$\nabla f(x) = \begin{bmatrix} 4x_1 \\ 2x_2 \end{bmatrix}$$

取述「冲力



■ 例子

令搜索方向

$$d^{(1)} = -\nabla f(x^{(1)}) = \begin{bmatrix} -4 \\ -2 \end{bmatrix}$$
$$\|d\| = \sqrt{16 + 4} = 2\sqrt{5} > 1/10$$

从x⁽¹⁾出发,沿方向d⁽¹⁾进行一维搜索,求步长入,即

$$\min_{\lambda \geq 0} \varphi(\lambda) = f(x^{(1)} + \lambda d^{(1)})$$

$$x^{(1)} + \lambda d^{(1)} = \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \lambda \begin{bmatrix} -4 \\ -2 \end{bmatrix} = \begin{bmatrix} 1 - 4\lambda \\ 1 - 2\lambda \end{bmatrix}$$

$$\varphi(\lambda) = 2(1-4\lambda)^2 + (1-2\lambda)^2$$

取还 门中/云



■ 例子

$$\Leftrightarrow \quad \varphi'(\lambda) = -16(1 - 4\lambda) - 4(1 - 2\lambda) = 0$$

$$\Rightarrow \quad \lambda_1 = 5/18$$

在直线上的极小点

$$x^{(2)} = x^{(1)} + \lambda_1 d^{(1)} = \begin{bmatrix} -1/9 \\ 4/9 \end{bmatrix}$$

$$f(x)$$
在点 $x^{(2)}$ 处的最速下降方向为

$$d^{(2)} = -\nabla f(x^{(2)}) = \begin{bmatrix} 4/9 \\ -8/9 \end{bmatrix}$$

$$||d^{(2)}|| = \frac{4}{9}\sqrt{5} > 1/10$$

取述「冲力



■例子

从x⁽²⁾出发,沿方向d⁽²⁾进行一维搜索:

$$\min_{\lambda \ge 0} \varphi(\lambda) = f(x^{(2)} + \lambda d^{(2)})$$

$$x^{(2)} + \lambda d^{(2)} = \begin{bmatrix} -1/9 \\ 4/9 \end{bmatrix} + \lambda \begin{bmatrix} 4/9 \\ -8/9 \end{bmatrix} = \begin{bmatrix} (-1+4\lambda)/9 \\ (4-8\lambda)/9 \end{bmatrix}$$

$$\varphi(\lambda) = \frac{2}{81}(-1+4\lambda)^2 + \frac{16}{81}(1-2\lambda)^2$$

$$\varphi'(\lambda) = \frac{16}{81}(-1 + 4\lambda) - \frac{64}{81}(1 - 2\lambda) = 0$$

$$\Rightarrow \lambda_2 = 5/12$$



取还 门中/云



■ 例子

得到

$$x^{(3)} = x^{(2)} + \lambda_2 d^{(2)} = \frac{2}{27} \begin{vmatrix} 1 \\ 1 \end{vmatrix}$$

第三次迭代

f(x)在点x⁽³⁾处的最速下降方向为

$$d^{(3)} = -\nabla f(x^{(3)}) = \frac{4}{27} \begin{bmatrix} -2\\ -1 \end{bmatrix}$$

$$||d^{(3)}|| = \frac{4}{27}\sqrt{5} > 1/10$$

取还门中/公



■ 例子

从x⁽³⁾出发,沿方向d⁽³⁾进行一维搜索:

$$\min_{\lambda \ge 0} \varphi(\lambda) = f(x^{(3)} + \lambda d^{(3)})$$

$$x^{(3)} + \lambda d^{(3)} = \frac{2}{27} \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \lambda \frac{4}{27} \begin{bmatrix} -2 \\ -1 \end{bmatrix} = \frac{2}{27} \begin{bmatrix} 1 - 4\lambda \\ 1 - 2\lambda \end{bmatrix}$$

$$\varphi(\lambda) = \frac{8}{27^2} (1 - 4\lambda)^2 + \frac{4}{27^2} (1 - 2\lambda)^2$$

取还门冲(石



■ 例子

$$x^{(4)} = x^{(3)} + \lambda_2 d^{(3)} = \frac{2}{27} \begin{bmatrix} -1/9 \\ 4/9 \end{bmatrix} = \frac{2}{243} \begin{bmatrix} -1 \\ 4 \end{bmatrix}$$

此时

$$\left\| \nabla f(x^{(4)}) \right\| = \frac{8}{243} \sqrt{5} < \frac{1}{10}$$

已经满足精度要求,得近似解

$$\tilde{x} = \frac{2}{243} \begin{bmatrix} -1 \\ 4 \end{bmatrix}$$

问题的最优解为x*=(0,0)

取还 I 中/石



■算法的收敛性

Theorem1.1 设f(x)是连续可微的实函数,解集合 $\Omega = \{\overline{x} | \nabla f(\overline{x}) = 0\}$,最速下降法产生的序列 $\{x^{(k)}\}$ 含于某个紧集,则序列 $\{x^{(k)}\}$ 的每个聚点 $\hat{x} \in \Omega$.

Theorem1.2 设 f(x) 存在连续二阶偏导, \overline{x} 是局部极小点 Hessian矩阵 $\nabla^2 f(\overline{x})$ 的最小特征值 a > 0,最大特征值为 A, 算法产生的序列 $\{x^{(k)}\}$ 收敛于 \overline{x} ,则目标函数序列 $\{f(x^{(k)})\}$ 以不大于 $\left(\frac{A-a}{A+a}\right)^2$ 的收敛比线性的收敛于 $f(\overline{x})$.

取还 门中/云



■算法的收敛性

在上述定理中, 若令r=A/a, 则

$$\left(\frac{A-a}{A+a}\right)^2 = \left(\frac{r-1}{r+1}\right)^2 < 1$$

r是对称正定矩阵 $\nabla^2 f(x)$ 的条件数.

定理表明:

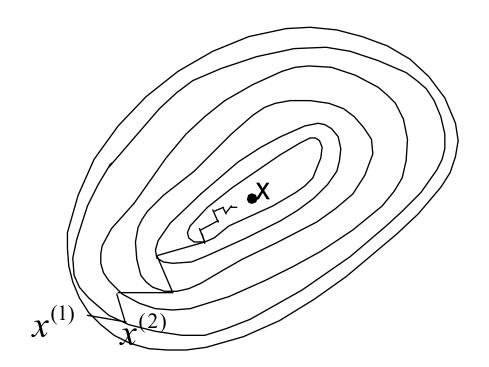
条件数越小,收敛越快;条件数越大,收敛越慢.

取还门中/公



■ 性质1

最速下降法存在锯齿现象



取还 I 中心



■ 性质2

容易证明,用最速下降法极小化目标函数时,相邻两个搜索方向是正交的.

令
$$\varphi(\lambda) = f(x^{(k)} + \lambda d^{(k)})$$

$$d^{(k)} = -\nabla f(x^{(k)})$$

$$\varphi'(\lambda) = \nabla f(x^{(k)} + \lambda_k d^{(k)})^T d^{(k)} = 0$$

$$\Rightarrow -\nabla f(x^{(k+1)})^T \nabla f(x^{(k)}) = 0$$

$$\Rightarrow d^{(k+1)} = -\nabla f(x^{(k+1)}) = d^{(k)} = -\nabla f(x^{(k)})$$

$$\Rightarrow \Delta^{(k+1)} = -\nabla f(x^{(k+1)}) = 0$$

十坝/云



■ 概念

设f(x)是二次可微函数, $x \in R^n$.又设 $x^{(k)}$ 是f(x)的极小点的一个估计,将f(x)在 $x^{(k)}$ 点Taylor展开,取二阶近似:

$$f(x) \approx \phi(x)$$
= $f(x^{(k)}) + \nabla f(x^{(k)})^T (x - x^{(k)}) +$

$$\frac{1}{2} (x - x^{(k)})^T \nabla^2 f(x^{(k)}) (x - x^{(k)})$$

其中 $\nabla^2 f(x^{(k)})$ 是f(x)在点 $x^{(k)}$ 处的Hessian矩阵.

丁でハム



■ 概念

为求φ(x)的驻点,令

$$\nabla \phi(x) = 0$$

即

$$\nabla f(x^{(k)}) + \nabla^2 f(x^{(k)})(x - x^{(k)}) = 0 \qquad (10.21)$$

设 $\nabla^2 f(x^{(k)})$ 可逆,则得牛顿法的迭代公式

$$x^{(k+1)} = x^{(k)} - \nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)}) \qquad (10.2.2)$$

算法(Newton法)

Step1,给定初始点 $x^{(0)}$,允许误差 $\varepsilon > 0$,置k = 1;

$$Step 2$$
, 若 $\|\nabla f(x^{(k)})\| \leq \varepsilon$, 停止, 得解 $x^{(k)}$; 否则, 令

$$x^{(k+1)} = x^{(k)} - \nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$
, $k = k+1, \ddagger 2$

十 " 八 不



■算法的收敛性

注意:牛顿法的迭代格式也可以从最速下降方向的角度来理解.

下面介绍一下A度量及其意义下的最速下降方向. 设A为对称正定矩阵,向量d的A范数定义为

$$\|d\|_{A} = \sqrt{d^{T}Ad}$$

下求A度量下的最速下降方向,为此,考虑

$$\min \quad \nabla f(x)^T d$$

$$s.t \quad d^T A d \le 1 \qquad (10.2.3)$$

十坝/石



■ 算法的收敛性

由 A, A^{-1} 对称正定,故存在对称平方根 $A^{1/2}, A^{-1/2}$,使得

$$A = A^{\frac{1}{2}}A^{\frac{1}{2}}, \qquad A^{-1} = A^{-\frac{1}{2}}A^{-\frac{1}{2}}$$

于是

$$d^{T} A d = d^{T} A^{\frac{1}{2}} A^{\frac{1}{2}} d = (A^{\frac{1}{2}} d)^{T} A^{\frac{1}{2}} d$$

$$\nabla f(x)^{T} d = \nabla f(x)^{T} A^{-\frac{1}{2}} A^{\frac{1}{2}} d$$

$$= (A^{\frac{1}{2}} \nabla f(x))^{T} A^{\frac{1}{2}} d$$

十ツ/乙



■ 算法的收敛性

令
$$y = A^{\frac{1}{2}}d$$
,则(10.2.3) 可写成 min $(A^{-\frac{1}{2}}\nabla f(x))^T y$ s.t $y^T y \le 1$ (10.2.4)

根据Schwartz不等式,得到

$$\left| (A^{-\frac{1}{2}} \nabla f(x))^T y \right| \le \left\| A^{-\frac{1}{2}} \nabla f(x) \right\| \|y\| \le \left\| A^{-\frac{1}{2}} \nabla f(x) \right\|$$

去掉绝对值符号,有

$$(A^{-\frac{1}{2}} \nabla f(x))^T y \ge - \left\| A^{-\frac{1}{2}} \nabla f(x) \right\|$$





■ 算法的收敛性

即

$$\nabla f(x)^T A^{-\frac{1}{2}} A^{\frac{1}{2}} d \ge - \left\| A^{-\frac{1}{2}} \nabla f(x) \right\|$$

$$\Rightarrow \nabla f(x)^T d \ge - \left\| A^{-\frac{1}{2}} \nabla f(x) \right\|$$

为得到在点x处下降最快的方向,按下式选取d

$$d = \frac{-A^{-1}\nabla f(x)}{(\nabla f(x)^{T} A^{-1}\nabla f(x))^{\frac{1}{2}}}$$
(10.2.5)

这时上式等号成立,由此确定的方向即**度量A意义 下的最速下降方向**

十坝/云



■ 算法的收敛性

若取

$$A = G_k = \nabla^2 f(x^k)$$

则牛顿法的搜索方向实际上是关于向量椭球范数 $\|\cdot\|_{G_k}$ 的最速下降方向,其步长为 $\|\nabla f(x^k)\|_{G_k}$.

十坝/石



■ 例子

例 用牛顿法求解下列问题

min
$$(x_1 - 1)^4 + x_2^2$$

取初点 $x^{(1)} = (0,1)'$

$$\nabla f(x) = \begin{bmatrix} 4(x_1 - 1)^3 \\ 2x_2 \end{bmatrix}, \nabla^2 f(x) = \begin{bmatrix} 12(x_1 - 1)^2 & 0 \\ 0 & 2 \end{bmatrix}$$

第1次迭代

$$\nabla f(x^{(1)}) = \begin{bmatrix} -4\\2 \end{bmatrix}, \nabla^2 f(x^{(1)}) = \begin{bmatrix} 12 & 0\\0 & 2 \end{bmatrix}$$

一大火ノム



■ 例子

$$x^{(2)} = x^{(1)} - \nabla^2 f(x^{(1)})^{-1} \nabla f(x^{(1)})$$
$$= \begin{bmatrix} 0 \\ 1 \end{bmatrix} - \begin{bmatrix} 12 & 0 \\ 0 & 2 \end{bmatrix}^{-1} \begin{bmatrix} -4 \\ 2 \end{bmatrix} = \begin{bmatrix} 1/3 \\ 0 \end{bmatrix}$$

第2次迭代

$$\nabla f(x^{(2)}) = \begin{bmatrix} -32/27 \\ 0 \end{bmatrix}, \nabla^2 f(x^{(2)}) = \begin{bmatrix} 48/9 & 0 \\ 0 & 2 \end{bmatrix}$$

$$x^{(3)} = x^{(2)} - \nabla^2 f(x^{(2)})^{-1} \nabla f(x^{(2)})$$

$$= \begin{bmatrix} 1/3 \\ 0 \end{bmatrix} - \begin{bmatrix} 48/9 & 0 \\ 0 & 2 \end{bmatrix}^{-1} \begin{bmatrix} -32/27 \\ 0 \end{bmatrix} = \begin{bmatrix} 5/9 \\ 0 \end{bmatrix}$$

十坝/云



■例子

第3次迭代

$$\nabla f(x^{(3)}) = \begin{bmatrix} -256/729 \\ 0 \end{bmatrix}, \nabla^2 f(x^{(2)}) = \begin{bmatrix} 64/27 & 0 \\ 0 & 2 \end{bmatrix}$$
$$x^{(4)} = x^{(3)} - \nabla^2 f(x^{(3)})^{-1} \nabla f(x^{(4)})$$
$$= \begin{bmatrix} 5/9 \\ 0 \end{bmatrix} - \begin{bmatrix} 64/27 & 0 \\ 0 & 2 \end{bmatrix}^{-1} \begin{bmatrix} -256/729 \\ 0 \end{bmatrix} = \begin{bmatrix} 19/27 \\ 0 \end{bmatrix}$$

继续下去,第4次迭代,...得到点列收敛于(1,0),此为最优解.

十坝/石



■局部收敛性

定理10.2.1 设f(x)是二次可微函数, $x \in E^n$ x满足 $\nabla f(\overline{x}) = 0$

且 $\nabla^2 f(x^{(k)})^{-1}$ 存在,又设初始点 $x^{(1)}$ 充分接近 \overline{x} ,使得存

在 $k_1, k_2 > 0$,满足 $k_1 k_2 < 1$,且对每一个

$$x \in X = \left\{ x \middle\| x - \overline{x} \middle\| \le \middle\| x^{(1)} - \overline{x} \middle\| \right\}$$
成立:

$$(1) \|\nabla^2 f(x^{(k)})^{-1}\| \le k_1,$$

$$(2)\frac{\left\|\nabla f(\overline{x}) - \nabla f(x) - \nabla^2 f(x)(\overline{x} - x)\right\|}{\left\|\overline{x} - x\right\|} \le k_2$$

则牛顿法产生的序列收敛于家.

一切么



证明:根据(10.2.2), 牛顿算法映射定义为

$$A(x) = x - \nabla^2 f(x)^{-1} \nabla f(x)$$
 (a)

定义解集合 $\Omega = \{\overline{x}\},$ 令函数 $\alpha(x) = \|x - \overline{x}\|$

下证 $\alpha(x)$ 是关于解集合 Ω 和算法A的下降函数.

$$\diamondsuit x \in X, \exists x \neq \overline{x}, \not \boxtimes \diamondsuit y \in A(x).$$

根据算法A的定义及 $\nabla f(\bar{x}) = 0$ 的假设,有

$$y - \overline{x} = x - \nabla^2 f(x)^{-1} \nabla f(x) - \overline{x}$$

$$= (x - \overline{x}) - \nabla^2 f(x)^{-1} [\nabla f(x) - \nabla(\overline{x})]$$

$$= \nabla f^2 f(x)^{-1} [\nabla(\overline{x}) - \nabla f(x) - \nabla^2 f(x) (\overline{x} - x)]$$
 (b)

一切么



于是可得

$$\|y - \overline{x}\| \le \|\nabla^2 f(x)^{-1}\| \|\nabla(\overline{x}) - \nabla f(x) - \nabla^2 f(x)(\overline{x} - x)\|$$

$$\le k_1 k_2 \|x - \overline{x}\| < \|\overline{x} - x\|$$
 (c)

从而 $\alpha(x)$ 是关于解集合 Ω 和算法A的下降函数

由(c)可知, $y \in X$,故迭代产生的序列 $\{x^{(k)}\}\subset X$ 根据定义知X是紧集,故迭代产生的序列含于紧集.此外,算法映射A在紧集X上是闭的.

综上, 迭代产生的序列 $\{x^{(k)}\}$ 必收敛于 \overline{x} .

十坝/云



■局部收敛性

定理(局部收敛定理)设函数 $f \in C^2(R^n)$, 它在 x^* 的 梯度 $\nabla f(x^*) = 0$, Hesse矩阵 $\nabla^2 f(x^*)$ 正定. 若初始点 x^0 充分靠近 x^* , 并且Hesse矩阵 $G(x) = \nabla^2 f(x)$ 满足 Lipschitz条件, 即存在L > 0, 使得 $\forall x, y \in R^n$, 有 $\|G(x) - G(y)\| \le L \|x - y\|$,

则对 \forall k,迭代格式(10.2.2)有意义,且迭代点序列(x^k)以二阶的收敛速度收敛到 x^* .

一坝/云



■局部收敛性

当牛顿法收敛时,有下列关系

$$\left\|x^{(k+1)} - \overline{x}\right\| \le c \left\|x^{(k)} - \overline{x}\right\|^2$$

c是某个常数,因此算法至少是2阶收敛的.

特别的,对于二次凸函数,用牛顿法求解,经一次迭代即达到极小点.设有二次凸函数

$$f(x) = \frac{1}{2}x^{T}Ax + b^{T}x + c$$

其中A是对称正定矩阵



• 注意, 当初始点远离极小点时, 牛顿法可能不收敛

•阻尼牛顿法

基本思想:增加了沿牛顿方向的一维搜索.

迭代公式为

$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$$

其中 $d^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$ 为牛顿方向, λ_k 是由

一维搜索所得的步长,即满足

$$f(x^{(k)} + \lambda_k d^{(k)}) = \min_{\lambda} f(x^{(k)} + \lambda d^{(k)})$$

十坝/云



• 算法(阻尼牛顿法)

Step1,给定初始点 $x^{(0)}$,允许误差 $\varepsilon > 0$, 置 =1;

$$Step 2$$
, 计算 $\nabla f(x^{(k)})$, $\nabla^2 f(x^{(k)})^{-1}$

Step 3, 若 $\|\nabla f(x^{(k)})\| \leq \varepsilon$, 停止, 得解 $^{(k)}$; 否则, 令

$$d^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

Step 4,从 $x^{(k)}$ 出发,沿方向 $d^{(k)}$ 作一维搜索:

$$\min_{\lambda} f(x^{(k)} + \lambda d^{(k)}) = f(x^{(k)} + \lambda_{k} d^{(k)})$$

$$\Rightarrow x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$$

Step 5, 置k := k + 1, 转2



■ 存在问题

显然可能存在:

- 1) Hessian 矩阵 $\nabla^2 f(x^{(1)})$ 奇异-不可逆
- 2) 即使非奇异,Hessian 矩阵 $\nabla^2 f(x^{(1)})$ 也可能非正定

牛顿方向不一定是下降方向,算法失效!

一大火ノム



■ 例子

•例 用阻尼牛顿法求解下列问题

$$\min f(x) = x_1^4 + x_1 x_2 + (1 + x_2)^2$$

取初点 $x^{(1)} = (0,0)^T$.在该点函数的梯度和Hessian阵为

$$\nabla f(x^{(1)}) = \begin{bmatrix} 0 \\ 2 \end{bmatrix}, \nabla^2 f(x^{(1)}) = \begin{bmatrix} 0 & 1 \\ 1 & 2 \end{bmatrix}$$

牛顿方向

$$d^{(1)} = -\nabla^2 f(x^{(1)})^{-1} \nabla f(x^{(1)})$$

$$\begin{bmatrix} 0 & 1 \end{bmatrix}^{-1} \begin{bmatrix} 0 \end{bmatrix} \begin{bmatrix} -2 \end{bmatrix}$$

$$= \begin{bmatrix} 0 & 1 \\ 1 & 2 \end{bmatrix}^{-1} \begin{bmatrix} 0 \\ 2 \end{bmatrix} = \begin{bmatrix} -2 \\ 0 \end{bmatrix}$$

一世以八乙



例子

 $\mathcal{M}_{x}^{(1)}$ 出发,沿方向 $d^{(1)}$ 进行一维搜索,令

$$\varphi(\lambda) = f(x^{(1)} + \lambda d^{(1)}) = 16\lambda^4 + 1$$

再令
$$\varphi'(\lambda) = 0 \Rightarrow \lambda_1 = 0$$

显然,用阻尼牛顿法不能产生新点,而点 $x^{(1)}=(0,0)$ T并不是问题 极小点.可见从x(1)出发,用阻尼牛顿法求不出问题的极小点,原 因在于 Hessian 矩阵 $\nabla^2 f(x^{(1)})$ 非正定

十坝/石



■修正牛顿法

考虑 (10.2.2),记搜索方向 $d^{(k)} = x - x^{(k)}$

$$\nabla^2 f(x^{(k)}) d^{(k)} = -\nabla f(x^{(k)})$$
 (d)

阻尼牛顿法所用搜索方向是上述方程的解

$$d^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$
 (e)

此处假设逆矩阵 $\nabla^2 f(x^{(k)})^{-1}$ 存在

十坝/云



■ 修正牛顿法

解决Hessian矩阵 $\nabla^2 f(x^{(k)})$ 非正定问题的基本思想修正 $\nabla^2 f(x^{(k)})$,构造一个对称正定矩阵 G_k ,在方程(d)中用 G_k 取代矩阵 $\nabla^2 f(x^{(k)})$:

$$G_k d^{(k)} = -\nabla f(x^{(k)})$$
 (f)

$$\Rightarrow d^{(k)} = -G_k^{-1} \nabla f(x^{(k)})$$
 (g)

再沿此方向作一维搜索

如何构造 G_k ?比如,可令

$$G_k = \nabla^2 f(x^{(k)}) + \varepsilon_k I \tag{h}$$

其中I是单位阵, ε_{k} 是一个适当的正数.

十坝/云



■修正牛顿法

Step1,给定初始点 $x^{(0)}$,允许误差 $\varepsilon > 0$,置 k=0; Step 2, 计算梯度 $g^k = \nabla f(x^{(k)})$, 若 $\|\nabla f(x^{(k)})\| \le \varepsilon$, 停止, 得解 $x^{(k)}$; 否则转Step3 Step3, 计算Hesse矩阵 $G_k = \nabla^2 f(x^{(k)})$, 置矩阵 $B_k = G_k + E_k$ 其 中 E_{ι} 为修正矩阵(当 G_{ι} 正定时,它取0),计算修正牛顿方向 $d^{(k)} = -(B_{k})^{-1} \nabla f(x^{(k)})$ Step4,从 $x^{(k)}$ 出发,沿方向 $d^{(k)}$ 作(精确或非精确)一维搜索:

$$\min_{\lambda} f(x^{(k)} + \lambda d^{(k)}) = f(x^{(k)} + \lambda_k d^{(k)})$$

令
$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$$
, 置 $k := k+1$, 转 2

十坝/石



■修正牛顿法

定理(全局收敛定理) 设 $f: R^n \to R$ 在某开集D上二阶连续可微,且修正牛顿法的初始点 $x^0 \in D$ 使得f的水平集 $S_{f(x^0)} = \{x \in D \mid f(x) \leq f(x^0)$ 是紧集. 若矩阵序列满足有界分解特性,则 $\lim_{x \to \infty} \nabla f(x^k) = 0$.

最优性条件



■ 小结

- > 使用导数基本概念
- ▶ 最速下降法
- > 牛顿法

小结和作业



■ 作业

▶ 习题 3、4、5、10、14、17、18、19